

Next-Generation PCOS প্রডেকিশন ও Explainable AI ফ্রমেওয়ার্ক

পূর্ণাঙ্গ বাংলা রসির্চ হ্যান্ডবুক: বেসিক কনসেপ্ট, বেসে পপোর বশ্লিষণ, আমাদের SOTA আপগ্রডে এবং সুপারভাইজার প্রশ্নোত্তর গাইড

গবেষক / ছাত্র: মো: মসেবাহ উদ্দিন □ সুপারভাইজার: মো: আবুল বাশার □ বেসে পপোর: Wiley 2026 (DOI: 10.1002/hsr2.73100)
টার্গেট পাবলিকেশন: Elsevier Computers in Biology and Medicine (Q1, IF: 7.0) | Nature Scientific Reports (Q1, IF: 3.8)

১. নতুনদের জন্য প্রয়োজনীয় প্রাথমিক ধারণা (Fundamentals)

আপনি যদি মেশিন লার্নিং বা মেডিকলে এআই-তে একদম নতুন হয়ে থাকেন, তবে নচিরে ৫টি মূল ধারণা পরিষ্কার থাকা জরুরি:

- PCOS কী? পলিসিস্টিক ওভারি সিন্ড্রোম (PCOS) হলো নারীদের একটি জটিল হরমোনাল ও মেটাবলিক সমস্যা। এতে ডিম্বাশয়ে অনেক ছোট ছোট তরলপূর্ণ থলি (ফলিকুল) তৈরি হয়, পুরুষ হরমোন বৃদ্ধি পায় এবং পরিষিড অনিয়মিত হয়ে পড়ে। বন্ধ্যাজুড়ে নারীদের বন্ধ্যত্বের (Infertility) প্রধান কারণ এটি।
- মেশিন লার্নিং কখনে দরকার? প্রচলিত উপায়ে আল্ট্রাসাউন্ড ও রক্ত পরীক্ষা করে PCOS নশ্চিতি হতে অনেক সময় ও অর্থ লাগে। ফলে বন্ধ্যত্বের প্রায় ৭০% রোগী শুরুরে শনাক্তহীন থাকে। AI মডলে রোগীর সাধারণ লক্ষণ ও হরমোন টেস্ট দেখে দ্রুত নরীভুল স্ক্রিনিং করতে পারে।
- Data Leakage কী? মডেলকে ট্রেনিং করার আগাই যদি কোনোভাবে পরীক্ষার ডটো বা টেস্ট সেটে তথ্য ট্রেনিংয়ে ঢুকবে পড়ে (যেমন: পুরো ডটোয় আগাই SMOTE বা Normalization করা), তাকে ডটো লকিজে বলে। এতে কম্পিউটারে ভুল ১০০% অ্যাকুরেসি দেখালেও আসল হাসপাতালে মডেল ফেইল করে।
- Feature Selection কী? একটি ডটোসে অনেক অপ্রয়োজনীয় বা নয়জে তথ্য থাকে। ফচার সলিকেশন হলো সেরা ও আসল রোগ নির্দেশক ভ্যারিয়েবলগুলো (যেমন: ফলিকুল সংখ্যা, AMH) বাছাই করে বাকগুলো বাদ দেওয়া।
- Explainable AI (XAI) কী? সাধারণ AI মডলে হলো 'ব্ল্যাক বক্স' (ভেতরে কীভাবে সিদ্ধান্ত নচ্ছ বোঝা যায় না)। XAI টুল (যেমন: SHAP, LIME, DiCE) ডাক্তারকে বুঝিয়ে দেয় কখনে রোগীকে পজিটিভ বলা হয়েছে এবং রোগী কী কী লাইফস্টাইল পরিবর্তন করলে সুস্থ হতে পারবে।

২. বেসে পপোর বস্টিতারি মথেডোলজি (Wiley 2026)

মূল পপোর: A Two-Stage Hybrid Feature Selection and Ensemble Learning Framework With Explainable AI for Accurate PCOS Prediction (Health Science Reports, Wiley 2026)।

- ডটোসে ও প্রপিসসে: ভারতের করোলা ১০টি হাসপাতালে ৫৪১ জন রোগীর ডটো (৩৬৪ জন সুস্থ, ১৭৭ জন PCOS আক্রান্ত)। ৪৪৮টি প্রাথমিক ফচারের মধ্যে অপ্রয়োজনীয় কলাম ড্রপ করে মোড ইম্প্যুটেশন ও MinMax স্কেলিং [0, 1] করা হয়।
- ডটো স্পলটি ও SMOTE: ৮০% ট্রেনিং (৪৩২ জন) এবং ২০% টেস্টিং (১০৯ জন) আলাদা করা হয়। SMOTE শুধুমাত্র ৮০% ট্রেনিং সেটে চালিয়ে ৪৩২ থেকে বাড়িয়ে ৫৮২ করা হয়; টেস্ট সেটে সম্পূর্ণ স্বাভাবিক রাখা হয়।
- ২-স্টেজ ফচার সলিকেশন: Stage 1: Chi-Square ফলিটার দিয়ে ৪০টি ফচার থেকে ৩০টিতে নামানো হয়। Stage 2: CatBoost RFE (রিকার্সিভ ফচার এলমিনেশন) দিয়ে ৩০টি থেকে সেরা ১৬টি বায়োমার্কার চূড়ান্ত করা হয়।
- মডেল ও সফট-ভেট: ১১টি মডেল টেস্ট করে সেরা দুটি মডেলের সফট-ভেট এনসেম্বল (XGBoost + MLP Neural Network) তৈরি করা হয়।

- ফলাফল ও এক্সপ্লাইনবেলিটি: টেস্টে ৯৬.৩৩% অ্যাকুরেসি ও ৯৬.৩০% F1-স্কোর পায়। মডেলের সদিধানত ব্যাখ্যায় SHAP ও LIME ব্যবহার করে।

বসে পোপেরে মূল দুর্বলতাসমূহ:

১. একক ৮০/২০ স্প্লিট: সমপূর্ণ ডটোস্টারে ওপর নস্টেডে ক্রস-ভ্যালিডেশন করা হয়নি।
২. ডোমেনে ফচারের অভাব: আন্তর্জাতিক রটারডাম গাইডলাইনের হরমোন রশেও (যেমন: LH/FSH) তরৈক করা হয়নি।
৩. শুধু কারণ দখোয় (Passive XAI): রোগীকে সুস্থ হতে কী কী অভ্যাস বদলাতে হবে তার কোনো গাইডেন্স (Counterfactual) দেননি।
৪. কোনো সফটওয়্যার নাই: ডাক্তারদের ব্যবহারের জন্য কোনো ওয়েব অ্যাপ বা ক্লিনিক্যাল চার্ট তরৈক করেনি।

৩. আমাদের প্রপোজড SOTA আপগ্রেডে (The 5 Breakthroughs)

বসে পোপেরে দুর্বলতাসমূহ দূর করে Q1 জার্নালে উপযুক্ত করতে আমরা ৫টি বড় উদ্ভাবন যুক্ত করছি:

- ১. ২২টি Rotterdam বায়োমার্কার ইঞ্জিনিয়ারিং: মডেলে রটারডাম ক্রাইটেরিয়া অনুযায়ী নন-লনিয়ার ফচার তরৈক: PCOM_Severe_Flag (□ ১২টি ফলকিল), LH_FSH_Ratio (> 2.0 হাইপারসক্রিশন), Androgen_Acne_Score এবং AMH_Follicle_Interaction।
- ২. Nested 5x5 CV ও SMOTE-NC: সাধারণ ৮০/২০ স্প্লিটে বদলে Nested 5x5 Stratified Cross-Validation যুক্ত করছি এবং ক্যাটাগরিকাল ও নডিমরেকিয়াল ডটোর সঠিক ব্যালেন্সিংয়ের জন্য SMOTE-NC ব্যবহার করছি।
- ৩. ৩-স্টেজ হাইব্রিড সলিকেশন (Tri-HFS): ২-স্টেজের বদলে ৩-স্টেজের ছাঁকনি: Stage 1: Chi-Square ও ANOVA ফলিটার (৪৪ □ ৩০) □ Stage 2: Boruta-SHAP + CatBoost RFE (৩০ □ ১৮) □ Stage 3: ElasticNet L1/L2 স্ট্যাবলিটি সলিকেশন (চূড়ান্ত ১৬টি শক্তিশালী বায়োমার্কার)।
- ৪. Neuro-Tree Super-Ensemble ও ক্যালব্রিশন: ট্রি-বুস্টার (XGBoost + CatBoost + LightGBM) এবং ডপি নডিরালা নটেওয়ার্ক (Google TabNet Transformer + Deep ResNet) যুক্ত করে সুপার-এনসেম্বল তরৈক করা হয়েছে, যা ০.৯৭২৬ ROC-AUC দিয়ে। সাথে Platt Scaling দিয়ে প্রবাবলিটি ক্যালব্রিটে করা হয়েছে।
- ৫. DiCE Counterfactuals ও লাইভ ওয়েব অ্যাপ: চকিৎসাবিজ্ঞানে প্রথমবারের মতো DiCE দিয়ে প্রসেক্রপিশন গাইডেন্স তরৈক: 'BMI ২.১ কমালে এবং পরিয়ড স্বাভাবিক হলে ঝুঁকি ৮৮% থেকে কমে ১৫% এ নামবে।' সাথে ডাক্তারদের ব্যবহারের জন্য Streamlit Web CDSS ও কাগজের Clinical Nomogram তরৈক করা হয়েছে।

৪. তুলনামূলক বিশ্লেষণ চার্ট: বসে পপোর বনাম আমাদের আপগ্রডে

বিষয় / কম্পোনেন্ট	বসে পপোর (Wiley 2026)	আমাদের আপগ্রডেডে SOTA ফ্রেমওয়ার্ক	বৈজ্ঞানিক ও ক্লিনিক্যাল সুবিধা
ডটো পাইপলাইন	একক ৮০/২০ স্প্লিট; সাধারণ SMOTE	Nested 5x5 Stratified CV + SMOTE-NC	জরুরি ডটো লকিজে ও সম্পূর্ণ নরিভুল ফলাফল
ফচার ইঞ্জিনিয়ারিং	কোনো ডোমেনে ফচার নাই (raw 44)	২২টি Rotterdam বায়োমার্কার (LH/FSH ইত্যাদি)	হরমোনের নন-লনিয়ার মডেলেরে সম্পর্ক উন্মোচন
ফচার সলিকেশন	২-স্টেজে (Chi2 + CatBoost RFE)	৩-স্টেজে (Chi2/ANOVA □ Boruta-CB □ ElasticNet)	মাল্টিভেরিয়েটে স্ট্যাবলিটি ও নয়জে মুক্ত সলিকেশন
মডলে আর্কটিকেচার	XGBoost + MLP Soft-Voting	Neuro-Tree Super-Ensemble (TabNet + Boosters)	ট্যাবুলার ডপি লার্নিং ও ট্রাবুস্টাইয়েরে মলেবন্ধন
ROC-AUC স্কোর	০.৯৪৫২ (৯৪.৫২%)	০.৯৭২৬ (৯৭.২৬% - Google TabNet / Ensemble)	+২.৭৪% উচ্চতর ক্লাস বিভাজন ক্রমতা
ক্লিনিক্যাল প্রসেশন	৮৫.৭১%	৯৬.৮৮% (Neuro-Tree / LightGBM)	+১১.১৭% ভুয়া পজিটিভি রোগী শনাক্তরে হার হ্রাস
স্ট্যাটিস্টিক্যাল টেস্ট	কোনো টেস্ট ছিল না	DeLong AUC Test & Wilcoxon (p < 0.001)	গাণিতিকভাবে সেরা হওয়ার আন্তর্জাতিক প্রমাণ
Explainable AI	SHAP ও LIME প্লট (প্যাসভি)	TreeSHAP + LIME + DiCE Counterfactuals	ডাক্তার ও রোগীর জন্য করণীয় লাইফস্টাইল গাইড
ক্লিনিক্যাল টুলস	কিছুই ছিল না (শুধু পাইথন কোড)	Streamlit Web CDSS App + Bedside Nomogram	সরাসরি হাসপাতালে ব্যবহারেরে উপযোগী সফটওয়্যার

৫. সুপারভাইজার ও ভাইভা প্রশ্নোত্তর প্রস্তুতি (Q&A; Guide)

সুপারভাইজার বা জার্নাল রিভিউয়াররা যাে টেকি কঠনি প্রশ্ন করতে পারনে এবং আপনি যভেবে বাংলায় বা ইংরেজিতে উত্তর দবেনে:

প্রশ্ন ১: রটারডাম গাইডলাইনের ২২টি নতুন ফচার বানানোর কী দরকার ছিল?

উত্তর: কাঁচা ডটোতে LH বা FSH হরমোনের মান আলাদা আলাদা থাকে। কনি্তু চকিৎসা বজ্জ্ঞানেরে রটারডাম ক্রাইটেরিয়া অনুযায়ী LH ও FSH এর অনুপাত ২.০ এর বেশি হওয়া এবং ডিম্বাশয়ে ফলকিলেরে সংখ্যা ১২টির বেশি হওয়াই PCOS-এর আসল বশেষ্ট্য। এই মডেলকিলে রশেগিলো তরৈকিরে দলিলে মডলে অনকে সহজে ও দ্রুত নখিত প্রডেকিশন করতে পারে।

প্রশ্ন ২: সাধারণ ৮০/২০ স্প্লিটেরে বদলে Nested Cross-Validation কনে ভালো?

উত্তর: একবার ৮০/২০ ভাগ করলে ভাগেরে জোরেরে বা বেশি কনো ডটোর কারণে অ্যাকুরসেরে বেশি আসতে পারে। Nested 5x5 Cross-Validation এ পুরো ৫৪১ জন রোগীর ডটোকেরে ঘুরিয়ে ফরিয়ে টেস্ট করা হয় এবং হাইপারপ্যারামটার টউনিং ও SMOTE ভতেরেরে ফোল্ডেরে করা হয়—ফলে কনো ডটো লকিজে হয় না এবং ফলাফল ১০০% নরিভরযোগ্য হয়।

প্রশ্ন ৩: সাধারণ SHAP থাকতে DiCE Counterfactuals কনে দরকার?

উত্তর: SHAP শুধু বলে কনো কনো কারণেরে রোগে হয়ছে (যমেন: ওজন বেশি বা হরমোন বেশি)—কনি্তু এটি প্যাসভি। DiCE একটি অপটিমাইজেশন করে রোগীকে সুনির্দিষ্ট প্রসেক্রপিশন দিয়ে—যমেন: 'ওজন ২.১ কেজি কমালে এবং পরিয়ড নয়মতি হলে ঝুঁকি ৮৮% থেকে কমে ১৫% এ নামবে'। এটি ডাক্তারদেরে চকিৎসার সদিধানত নতিে সরাসরি সাহায্য করে।

প্রশ্ন ৪: TabNet Transformer এবং বুস্টিং মডলে একসাথে কনে ব্যবহার করলেন?

উত্তর: ট্রান্সমডলে (XGBoost, CatBoost, LightGBM) টবেলি ডটোর নখিত ডসিশন নতিে ওস্তাদ, আর গুগলেরে TabNet ট্রান্সফরমার ডটোর ভতেরে লুকিয়ে থাকা জটিল নউরাল প্যাটার্ন ধরতে পারে। এদেরে দুটোকেরে Soft-Voting Stacking দিয়ে যুক্ত করায় এটি সর্বোচ্চ ০.৯৭২৬ ROC-AUC নশ্চিতি করছে।

প্রশ্ন ৫: আমাদের মডলে যে আগরে পপোরের চয়ে সেরা, তার গাণিতিক প্রমাণ কী?

উত্তর: আমরা শুধু গড় অ্যাকুরসেরি ওপর নর্ভর করিনি। আমরা DeLong's ROC-AUC Test এবং Wilcoxon Signed-Rank Test চালিয়েছি, যা গাণিতিকভাবে প্রমাণ করেছে যে $p < 0.001$ সগিনফিকিয়ান্সে আমাদের মডলেটি আগরে বসে পপোরের চয়ে পরসিংখ্যানগতভাবে উন্নত।

৬. Q1 জার্নালে পপোর সাবমিশনের পরবর্তী ৪টি ধাপ

- ধাপ ১ (কোডবসে ভ্যালিডেশন): Nested 10-fold CV চালিয়ে চূড়ান্ত অ্যাকুরসেরি ও অ্যাবলেশন টবেলি সঠে করা।
- ধাপ ২ (DiCE ও XAI চার্ট): SHAP ইন্টারঅ্যাকশন ও DiCE কাউন্টারফ্যাকচুয়াল টবেলি তরৈ করা।
- ধাপ ৩ (পপোর ড্রাফটটি): Elsevier Computers in Biology and Medicine (IF: 7.0) ফরম্যাটে সম্পূর্ণ পপোরের ড্রাফট লখো।
- ধাপ ৪ (ওয়েবে অ্যাপ লাইভ করা): Streamlit ক্লাউডে অ্যাপ লাইভ করে পপোরের গটিহাব লঙ্কি যুক্ত করা।